Evaluación de modelos

Material didáctico original para DocuChat AI

¿Por qué evaluar?

Después de entrenar un modelo supervisado, se necesita comprobar qué tan bien generaliza a observaciones nuevas. No basta con medir su rendimiento en los ejemplos de entrenamiento.

Matriz de confusión

Para clasificación binaria, la matriz de confusión contiene verdaderos positivos (VP), falsos positivos (FP), verdaderos negativos (VN) y falsos negativos (FN). Un positivo real correctamente detectado es VP, mientras que un positivo real omitido es FN.

Exactitud

Exactitud (accuracy) = (VP + VN) / (VP + VN + FP + FN). Esta medida resume el porcentaje de predicciones correctas, pero puede resultar engañosa si una clase es mucho más frecuente que la otra.

Precisión

Precisión (precision) = VP / (VP + FP). Responde: de todos los casos que el modelo señaló como positivos, ¿qué proporción fue realmente positiva? Es útil cuando los falsos positivos son costosos.

Recall o sensibilidad

Recall, o sensibilidad = VP / (VP + FN). Responde: de todos los casos que sí eran positivos, ¿qué proporción detectó el modelo? Es importante cuando omitir un positivo es especialmente costoso.

Si una métrica tiene denominador cero, se debe especificar cómo se maneja el caso; la fórmula por sí sola no define un resultado.

F1, validación y ejemplo

Material didáctico original para DocuChat AI

F1-score

La puntuación F1 es la media armónica entre precisión y recall: F1 = 2 × precisión × recall / (precisión + recall), siempre que el denominador sea positivo. Se utiliza cuando interesa equilibrar ambas métricas.

Ejemplo numérico ficticio

Imagina un conjunto didáctico de 100 casos, donde VP = 30, FP = 10, VN = 50 y FN = 10. Entonces la exactitud es 0.80; la precisión es 30/40 = 0.75; el recall es 30/40 = 0.75 y F1 = 0.75. Son cifras inventadas para mostrar los cálculos, no resultados experimentales.

Validación cruzada

La validación cruzada divide repetidamente los datos de entrenamiento en subconjuntos y alterna las porciones de ajuste y validación. Ayuda a comparar modelos, pero nunca debe permitir que información del conjunto de prueba final intervenga en la selección.

Elección de métricas

En clasificación desbalanceada, la exactitud puede ser alta aunque el modelo ignore la clase minoritaria. Por ello es recomendable reportar precisión, recall, F1 y matriz de confusión. La métrica principal depende del objetivo del problema.

Evaluación de regresión

En regresión suelen emplearse MAE (error absoluto medio), MSE (error cuadrático medio) y RMSE (raíz del MSE). Miden discrepancias entre predicciones numéricas y valores observados.

Reproducibilidad

Para comparar algoritmos de forma justa, utilice la misma partición o protocolo de validación, documente semillas aleatorias cuando aplique y guarde la configuración usada.